

기술 질문 답변서

영상 기반 오프라인 광고 주목도 측정 시스템 (신한 해커톤 · KLLJS)

보내주신 아홉 가지 질문에 대해 실무 관점에서 답변을 정리했습니다. 각 항목 아래에 판단의 근거가 된 논문과 평가 보고서를 함께 붙였으니, 수치의 출처가 궁금할 때 참고하시면 됩니다.

1. 단일 이미지 정확도 상한

먼저 성별과 연령을 나눠서 봐야 합니다. 두 과제의 난이도가 완전히 다르기 때문입니다. 성별은 정면에서 가깝고 해상도가 충분한 얼굴이라면 95% 이상도 가능합니다. 실제로 유명한 사진처럼 품질이 좋은 데이터셋에서는 99%가 넘는 수치가 보고됩니다. 문제는 옥외 카메라가 마주하는 얼굴이 그런 얼굴이 아니라는 점입니다. 무보정 스냅샷으로 구성된 Adience 같은 인더와일드 벤치마크로 내려오면 잘 만든 모델도 88~93% 선에서 움직입니다. 지금 시스템이 마주할 환경은 Adience 쪽에 훨씬 가깝다고 보시면 됩니다.

연령은 상황이 더 어렵습니다. 통제된 데이터셋 기준으로 현재 최고 수준 모델의 평균 오차(MAE)가 4세 언저리이고, 이 수치는 몇 년째 크게 내려가지 않고 있습니다. 사람이 라벨링한 정답 자체에 몇 세 단위의 편차가 있어서, 모델이 라벨 노이즈 수준에 도달해버린 것이 정체의 큰 이유입니다. MAE 4세라는 건 10세 단위 구간 분류로 환산하면 경계 근처 인물이 수시로 옆 구간으로 넘어간다는 뜻이라, 인더와일드에서 연령 구간 정확도는 60~75%대에 머뭙니다. 결국 단일 프레임의 연령 추정은 애초에 흔들리는 값이고, 이걸 시간 축으로 누적해 안정화하는 지금의 설계가 맞는 방향입니다. 단일 이미지 품질을 끌어올리는 노력은 필요하지만, 그것만으로 7구간 분류를 신뢰 수준까지 가져가기는 어렵다는 것이 솔직한 답입니다.

참고 자료

- [MiVOLO \(arXiv 2307.04616, 2023\)](#) — 얼굴과 상반신을 함께 입력받는 연령·성별 추정 모델. IMDB-clean 기준 연령 MAE 3.97세, 성별 정확도 99.68%로 5개 벤치마크에서 최고 성능을 기록했습니다. 다만 IMDB-clean은 유명한 사진 위주라 이 수치는 입력 품질이 좋을 때의 상한으로 읽어야 합니다. 논문에서 모델이 사람 평가자의 연령 추정 정확도를 넘어섰다고 보고하는데, 뒤집어 말하면 사람이 만든 정답 라벨의 노이즈가 이 과제의 실질적 한계라는 이야기입니다.
- [Papers with Code — IMDB-Clean 연령 추정 리더보드](#) — 연령 추정 최고 기록을 추적하는 공개 리더보드입니다. 순위권 모델들의 MAE가 3.9~4.0세 부근에서 정체된 흐름을 직접 확인할 수 있고, 나중에 모델 교체를 검토할 때 후보를 고르는 용도로도 쓸 수 있습니다.
- [Age Group and Gender Estimation in the Wild with Deep RoR \(arXiv 1710.02985\)](#) — 인더와일드 벤치마크 Adience(무보정 Flickr 사진, 8개 연령 구간)에서의 성능 보고. 딥러닝 모델에 대규모 사전학습을 더해도 성별 93.24%, 연령 구간 약 67%에 그칩니다. 통제된 환경과 실환경의 격차, 그리고 연령 구간 분류가 60~75%대라는 본문 수치의 출처입니다.

2. 프레임 선별 vs 전체 투표

전체 투표보다 선별이 낫습니다. 영상 얼굴 인식 쪽 연구들이 반복적으로 확인한 결론인데, 저품질 프레임은 정보를 더해주는 게 아니라 노이즈를 더합니다. 특히 blur가 심하거나 측면인 얼굴에서 나온 연령 추정치는 틀린 방향으로 일관되게 치우치는 경향이 있어서, 다수결에 포함시키면 오히려 정답을 밀어냅니다. 트랙당 프레임이 수십 장씩 확보되는 상황이라면 상위 품질 프레임 몇 장으로 투표하는 편이 전체를 쓰는 것보다 정확하고, 연산도 훨씬 적게 듭니다.

선별 기준은 단순한 것부터 쌓으면 됩니다. 얼굴 크기, 검출 confidence, Laplacian variance로 잔 선명도, yaw 절대값으로 잔 정면도 정도만 조합해도 체감 효과가 있습니다. 여기서 한 단계 올리고 싶다면 학습형 품질 점수를 권합니다. 특히 MagFace 계열은 임베딩 벡터의 크기 자체가 품질 점수로 나오도록 학습되어 있어서, 임베딩을 뽑는 순간 품질 점수가 따라옵니다. 프레임별 추론이 이미 돌아가는 파이프라인이라면 추가 비용 없이 품질 가중 투표로 전환할 수 있다는 뜻입니다. 완전히 버리기 아까운 중간 품질 프레임은 제외하는 대신 가중치를 낮춰서 반영하는 절충도 실무에서 많이 씁니다.

참고 자료

- [SER-FIQ \(CVPR 2020, arXiv 2003.09373\)](#) — 별도 품질 라벨 없이, 인식 모델에 드롭아웃을 다르게 적용한 서브네트워크들의 임베딩이 얼마나 일관되는지를 품질 점수로 쓰는 기법입니다. 배포된 인식 모델 기준으로 "이 얼굴이 얼마나 쓸 만한가"를 직접 재기 때문에, 라벨링 비용 없이 선별 기준을 만들 수 있습니다.
- [MagFace \(CVPR 2021, arXiv 2103.06627\)](#) — 임베딩의 L2 norm이 이미지 품질에 비례하도록 학습하는 손실 함수를 제안한 논문. 인식용 임베딩을 계산하면 품질 점수가 부산물로 나오므로 추가 forward pass가 필요 없습니다. 실시간 파이프라인에 품질 가중 투표를 엮을 때 가장 부담이 적은 선택지입니다.
- [Efficient video face recognition based on frame selection and quality assessment \(PeerJ CS, 2021\)](#) — 블러·가림·저해상도 프레임을 걸러낸 뒤 인식하는 파이프라인을 실증한 연구. 저품질 프레임을 버리는 쪽이 전체 프레임을 쓰는 것보다 정확도를 유지하거나 개선하면서 연산량까지 줄인다는 결과를 보고합니다.

3. 평가 방법론

평가는 두 겹으로 가져가는 걸 권합니다. 모델 자체의 성능은 공개 벤치마크로 확인합니다. 성별·연령은 Adience, IMDB-clean, UTKFace, 헤드포즈는 AFLW2000과 BIWI가 표준이고, 지표는 성별 정확도, 연령 MAE와 구간 정확도, 헤드포즈는 yaw/pitch/roll 축별 MAE를 씁니다. 하지만 공개 벤치마크 점수는 참고치일 뿐입니다. 옥외 카메라의 화각, 조명, 얼굴 크기 분포는 벤치마크와 전혀 다르기 때문에, 최종 검증은 반드시 실제 설치 카메라 영상에서 뽑은 인도메인 평가셋으로 해야 합니다. 몇백 트랙 규모라도 자체 셋이 있으면 벤치마크 점수보다 훨씬 믿을 만한 판단 기준이 됩니다.

연령 ground truth가 까다로운 부분인데, 정답 자체가 흔들리는 값이라는 점을 받아들이고 시작해야 합니다. 사람도 사진 속 인물의 나이를 몇 세 단위로 틀립니다. 그래서 외견 연령 데이터셋들은 이미지 한 장에 라벨러 여러 명을 붙이고 평균과 표준편차를 같이 기록하는 방식을 씁니다. 자체 라벨링도 같은 방식을 권합니다. 라벨러 3인 이상의 중앙값을 정답으로 삼고, 라벨러 간 편차를 함께 남겨두면 "이 이하로는 모델을 쥐어짜도 의미가 없다"는 하한선이 생깁니다. 모델 오차가 라벨러 간 편차에 근접했다면 그 구간에서는 이미 할 만큼 한 것입니다.

참고 자료

- [ChaLearn LAP 외견 연령 추정 챌린지 \(CVPR 2016 Workshop\)](#) — 연령 라벨링 방법론의 대표 선례. 이미지당 10인 이상이 투표한 외견 연령의 평균과 표준편차를 함께 배포하는데, 이 표준편차가 곧 사람끼리도 이만큼 못 맞춘다는 라벨 노이즈의 정량값입니다. 피사체가 30세를 넘으면 편차가 커진다는 것, 즉 고연령일수록 정답 자체가 불확실하다는 점도 여기서 확인됩니다.
- [AFLW2000 / BIWI 벤치마크 프로토콜 \(6DRepNet 논문\)](#) — 헤드포즈 평가의 표준 프로토콜. AFLW2000은 인더와일드 사진 2,000장에 3D 포즈를 주석한 셋, BIWI는 실험실에서 심도 센서로 정답을 측정한 셋입니다. 자체 평가셋을 만들 때도 축별 MAE 지표를 그대로 따르면 공개 수치와 직접 비교할 수 있습니다.

4. 속성 편향

편향은 예외 상황이 아니라 기본값이라고 전제하는 게 안전합니다. NIST가 189개 알고리즘을 평가한 결과 대부분에서 인구통계 집단 간 성능 차이가 확인됐고, 여성·아동·고령자에서 오류가 높은 패턴이 반복적으로 나타났습니다. buffalo_1처럼 웹 수집 데이터로 학습된 모델은 학습 분포가 서구권·성인·정면 위주라, 국내 옥외 환경의 고령자나 아동에서 성능이 꺾일 가능성이 큼니다. 마스크는 별개의 큰 변수인데, NIST 평가에서 마스크 하나로 오류율이 수십 배 뛰는 알고리즘이 흔했습니다. 측정 방법은 단순합니다. 평가셋을 성별×연령대×마스크 여부×조명 조건으로 쪼개서 지표를 각각 뽑아보는 것부터 시작하면 되고, 특정 서브그룹에서 성능이 무너져 있다면 그 그룹 데이터를 보강해 파인튜닝하는 것이 가장 확실한 완화책입니다.

연령 구간 해상도에 대해서는 보수적으로 답하겠습니다. 모델 오차에 라벨 노이즈, 서브그룹 편향까지 겹치면 10세 단위 7구간을 신뢰 수준으로 서비스하기는 어렵습니다. 내부 집계는 7구간으로 돌리더라도, 대외 리포팅은 청소년/청년/중장년/노년 정도의 3~4구간으로 묶는 것을 권합니다. 상용 DOOH 측정 업체들도 대부분 이 정도 해상도로 상품을 만듭니다. 구간을 넓히면 정확도 수치가 올라가서 광고주 신뢰를 얻기에도 유리합니다.

참고 자료

- [NIST FRVT Part 3: Demographic Effects \(NISTIR 8280, 2019\)](#) — 미국 표준기술연구소가 99개 개발사의 알고리즘 189개를 평가한, 이 주제에서 가장 권위 있는

보고서입니다. 대부분의 알고리즘에서 인구통계 집단 간 성능 차이가 존재했고, 여성·아동·고령자에서 오인식이 높았으며 일부 인종 집단에서 오류가 체계적으로 증가했습니다.

- [NIST FATE: Age Estimation & Verification \(NIST IR 8525, 2024\)](#) — 상용 연령 추정 알고리즘 6종을 4개 데이터셋으로 평가한 최신 보고서. 상용 최고 수준에서도 오차가 피사체의 연령대·성별·출신 지역에 따라 체계적으로 달라짐을 보여줍니다. 평균 MAE 하나로 성능을 말할 수 없고 집단별로 봐야 한다는 본문 주장의 근거입니다.
- [NIST FRVT 마스크 영향 평가 \(NISTIR 8311, 2020\)](#) — 89개 상용 알고리즘 대상 마스크 영향 정량화. 비착용 시 오류율 0.3% 수준이던 상위 알고리즘도 착용 시 약 5%로 뛰었고, 일부는 10~40%까지 실패했습니다. 코 덮임 정도와 마스크 면적이 클수록 성능이 급락합니다.

5. 머리 방향의 주목 지표 활용

오차 수준부터 말씀드리면, 헤드포즈 상위 모델들의 벤치마크 MAE는 3~5° 범위이고 세 축 중 pitch가 가장 약합니다. 6DRepNet 기준으로 AFLW2000에서 yaw 3.63°, pitch 4.91°인데, 이걸 크고 선명한 얼굴에서의 수치입니다. 옥외의 소형·측면 얼굴에서는 10° 이상으로 잡는 게 안전합니다. 지금 설정을 보면 pitch 허용각이 $\pm 15^\circ$ 로 yaw($\pm 20^\circ$)보다 좁은데, 오차가 가장 큰 축에 가장 좁은 허용각이 걸려 있는 셈이라 이상적인 조건에서도 오차가 허용 폭의 3분의 1을 먹고 들어갑니다. 경계 근처에서 판정이 프레임마다 뒤집히는 현상이 있다면 이게 원인일 가능성이 높습니다.

허용각으로 주목을 판정하는 방식 자체는 타당합니다. 상용 DOOH 측정의 선두인 Quividi도 "얼굴이 센서 방향을 향한 시간"을 attention time으로 정의해서 팔고 있으니, 업계에서 검증된 접근이라고 봐도 됩니다. 다만 세 가지 보완을 권합니다. 첫째, 머리 방향과 시선은 다릅니다. 같은 머리 각도에서도 눈은 다른 곳을 볼 수 있다는 게 시선 추정 연구에서 실증된 사실이라, 지표 이름과 정의를 "주목 추정"으로 명확히 해두는 게 나중에 광고주 앞에서 방어하기 좋습니다. 둘째, 단일 프레임 판정 대신 연속 유지 시간 기준을 쓰세요. 1초 이상 유지될 때만 주목으로 집계하면 경계 노이즈가 대부분 사라집니다. 셋째, 지난번 논의된 것처럼 고정 허용각 대신 보행자 위치별 기대 시선각을 쓰면 판정이 한 단계 더 정확해집니다. 카메라 설치 시 1회 캘리브레이션으로 충분합니다.

참고 자료

- [6DRepNet \(arXiv 2202.12555\)](#) — 6D 회전 표현 기반 헤드포즈 모델. AFLW2000에서 yaw 3.63° / pitch 4.91° / roll 3.37°(평균 3.97°), BIWI에서 평균 3.47°를 기록했습니다. pitch 오차가 세 축 중 가장 크다는 점이 본문에서 지적한 허용각 설정 문제의 근거입니다.
- [Gaze360 \(MIT, ICCV 2019, arXiv 1910.10088\)](#) — 실내외 비통제 환경에서 238명의 시선을 수집한 대규모 연구. 머리 방향만으로 시선을 예측하는 베이스라인이 실제 시선 모델보다 일관되게 뒤쳐진다는 것을 실증해, 머리 방향은 시선의 근사치일 뿐이라는 본문 지적의 출처입니다.

- [Quividi](#) — 2006년부터 익명 얼굴 분석 기반 DOOH 측정을 해온 업계 선도 기업(46개국, 누적 30억 명 이상 분석). attention time을 "얼굴이 센서 방향을 향한 시간"으로 정의해 상품화하고 있어, 허용각 + 유지 시간 방식이 상용 서비스에서 검증된 표준임을 보여줍니다.

6. 재식별(Re-ID)

얼굴보다 몸을 쓰는 게 현실적입니다. 가림으로 트랙이 끊기는 순간은 대개 얼굴도 안 보이는 순간이라, 얼굴 임베딩으로 재연결하려면 끊긴 전후 양쪽에서 정면에 가까운 대형 얼굴이 잡혀야 하는데 옥외에서 그런 운은 자주 따라주지 않습니다. 사람 crop 기반 body Re-ID는 옷·체형 같은 전신 단서를 쓰기 때문에 얼굴이 안 보여도 동작합니다. 모델은 OSNet 계열을 권합니다. 표준 벤치마크에서 검증됐고 파라미터가 2.2M에 불과해 엣지에서도 부담이 없으며, 사전학습 가중치가 공개되어 있어 바로 붙여볼 수 있습니다. 거리 척도는 코사인 유사도면 충분합니다.

임계값은 공개 벤치마크 수치를 그대로 가져오면 안 됩니다. 카메라 화각과 조명이 다르면 유사도 분포 자체가 이동하기 때문에, 자체 영상에서 동일 인물 쌍과 타인 쌍의 유사도 분포를 그려보고 ROC 기준으로 잡아야 합니다. 그리고 경험상 오매칭을 줄이는 데 임계값 조정보다 효과적인 것이 게이팅입니다. 끊긴 지 수 초 이내, 마지막 위치에서 이동 가능한 범위 안의 후보만 매칭 대상으로 제한하면 옷차림이 비슷한 타인과의 오매칭이 대부분 걸러집니다. 통계 집계가 목적이라면 애매한 재연결은 포기하고 별도 트랙으로 남기는 편이 오히려 안전하다는 점도 말씀드립니다. 잘못 이어붙인 트랙은 체류 시간과 주목 시간을 동시에 오염시키기 때문입니다. 얼굴 임베딩은 고품질 정면 얼굴이 양쪽에 확보된 경우에 한해 보조 확인용으로만 쓰는 것을 권합니다.

참고 자료

- [OSNet \(ICCV 2019, arXiv 1905.00953\)](#) — 사람 재식별의 표준 백본 중 하나. 국소 특징(옷 무늬)부터 전역 특징(체형)까지 여러 스케일을 동시에 학습하는 구조로, Market-1501에서 Rank-1 94.8%, mAP 84.9%를 기록하면서 파라미터는 2.2M(ResNet50 기반의 약 1/10)에 불과합니다. torchreid 라이브러리로 사전학습 모델이 공개되어 있습니다.
- [MagFace \(arXiv 2103.06627\)](#) — 임베딩 크기가 품질을 나타내므로, 재연결 시 저품질 얼굴 임베딩을 매칭 후보에서 걸러내는 필터로 쓸 수 있습니다. 저품질끼리의 매칭이 오매칭의 주 원인이라는 점에서, 얼굴 재연결을 고품질 얼굴로 한정하라는 본문 권고의 구현 수단입니다.

7. 모델·입력·파인튜닝

실시간 제약이 크지 않다는 전제라면 업그레이드 여지가 꽤 있습니다. 연령·성별에서 가장 큰 폭의 개선은 MiVOLO 계열로 기대할 수 있습니다. buffalo_1과의 결정적 차이는 얼굴과 상반신을 함께 입력받는다라는 점인데, 옥외 통행자의 상당수는 측면이나 후면으로 지나가기 때문에 얼굴만 보는 모델은 그 사람들을 통째로 놓칩니다. MiVOLO는 얼굴이 안 보여도 상반신만으로 추정이 가능해서 집계 커버리지 자체가

달라집니다. 얼굴 검출은 같은 insightface 계열인 SCRFD의 대형 모델로 올리면 교체 비용 거의 없이 소형·측면 얼굴 검출률을 높일 수 있고, 헤드포즈는 6DRepNet 계열이 검토할 만합니다.

저해상도·측면 얼굴은 보정보다 제외를 권합니다. 초해상도 같은 생성 기반 보정은 없는 정보를 그럴듯하게 만들어내는 과정이라, 학습 데이터의 편향이 복원 결과에 스며듭니다. 보정된 얼굴로 연령을 추정하면 오차가 줄어드는 게 아니라 특정 방향으로 치우친 오차가 생깁니다. 통계 집계는 목적이려면 40px 컷오프처럼 제외 기준을 명확히 하고 남은 표본으로 집계하는 편이 방어하기 좋습니다. 파인튜닝은 효과가 확실한 투자입니다. 실제 설치 카메라의 각도·조명·해상도 분포는 어떤 공개 데이터셋과도 다르기 때문에, 그 분포에서 뽑은 데이터로 분류 헤드만 다시 학습해도 체감 개선이 있습니다. 백본을 건드리지 않으면 수천 장 규모의 라벨로 충분하고, 위 3번에서 말씀드린 다인 라벨링 방식으로 진행하면 평가셋과 파인튜닝셋을 같은 공정에서 확보할 수 있습니다.

참고 자료

- [MiVOLO \(arXiv 2307.04616\)](#) — 얼굴+상반신 cross-view fusion 구조로 얼굴 비가시 상황에서도 연령·성별 추정이 가능합니다. 5개 공개 벤치마크에서 최고 성능이며 코드와 가중치가 공개되어 있습니다. 기존 얼굴 기반 추정을 유지한 채 얼굴이 안 잡히는 구간의 보완 모델로 병행 도입하는 것도 가능합니다.
- [SCRFD \(arXiv 2105.04714\)](#) — insightface 프로젝트의 얼굴 검출기. 학습 샘플과 연산량을 검출 난이도에 맞게 재배분해 같은 연산량에서 더 높은 정확도를 내며, 0.5GF부터 34GF까지 모델 크기 선택지가 넓습니다. 이미 insightface 스택을 쓰고 있어 교체 비용이 거의 없습니다.
- [The Effect of Wearing a Face Mask on Face Image Quality \(arXiv 2110.11283\)](#) — 가림이 얼굴 이미지 품질 점수를 어떻게 떨어뜨리는지 정량화한 연구. 품질이 낮아진 입력은 이후 모든 속성 추정의 신뢰도를 연쇄적으로 떨어뜨린다는 점에서, 저품질 입력을 복원하기보다 컷오프로 제외하라는 본문 권고를 뒷받침합니다.

8. 데이터 파이프라인 구성

구조 자체는 단순하게 가져가는 걸 권합니다. 엣지에서 수집(영상 또는 검출된 crop) → 배치 추론 → 트랙 단위 집계 → 이벤트 저장 정도의 직선 구조면 충분하고, 복잡한 스트리밍 인프라는 이 규모에서 득보다 실이 큼니다. 정말 중요한 건 구조가 아니라 재처리 가능성입니다. 모델은 반드시 교체되고, 교체된 모델로 과거 데이터를 다시 집계해야 하는 순간이 옵니다. 그때를 위해 두 가지를 미리 해주세요. 첫째, 재처리의 원료를 보존합니다. 원본 영상을 보관할 수 있으면 가장 좋고, 개인정보 이슈로 어렵다면 얼굴·사람 crop 이나 임베딩+메타데이터라도 남깁니다. 둘째, 모든 결과 레코드에 그 결과를 만든 모델 버전과 설정 해시를 기록합니다. 이 태그가 있어야 "어느 기간의 집계가 어느 모델 산출물인지"를 구분할 수 있고, 문제가 발견됐을 때 해당 구간만 골라 재집계할 수 있습니다.

버전 관리 도구는 데이터와 모델을 나눠서 보면 됩니다. 데이터셋과 파이프라인 정의는 DVC로 Git처럼 버전을 관리하고, 모델의 버전·스테이지·성능 이력은 MLflow Model Registry로 관리하는 조합이

사실상의 표준입니다. 해커톤 규모에서 둘 다 도입하는 게 부담스럽다면, 최소한 결과 레코드의 모델 버전 태그와 평가셋의 버전 고정만큼은 처음부터 해두시길 권합니다. 나중에 붙이려면 과거 데이터가 전부 버전 불명이 되어버립니다.

참고 자료

- [DVC 공식 문서](#) — 대용량 데이터 파일은 원격 스토리지에 두고 해시만 Git으로 추적하는 데이터 버전 관리 도구. 전처리→추론→집계 파이프라인을 정의해두면 dvc repro로 전체를 재실행할 수 있어, 어떤 데이터와 모델로 이 결과가 나왔는지를 커밋 단위로 복원할 수 있습니다.
- [MLflow Model Registry 공식 문서](#) — 모델 버전, 스테이지(개발/스테이징/운영), 학습 파라미터와 성능 지표의 계보를 중앙 관리하는 도구. 결과 레코드의 모델 버전 태그를 레지스트리와 연결하면 기간별 집계의 출처 추적과 선택적 재집계가 가능해집니다.

9. 최적화 방향 설정

방향을 잡는 기준은 최종 산출물이 무엇이나에서 나옵니다. 이 시스템이 파는 것은 개인 단위 예측이 아니라 시간대별·인구통계별 주목물이라는 집계 지표입니다. 그렇다면 핵심 지표도 프레임 정확도가 아니라 집계 오차여야 합니다. 구체적으로는 일정 시간 구간을 사람이 직접 세어 만든 정답과 시스템 집계를 비교해서, 통행자 수·주목자 수·인구통계 구성비가 몇 % 어긋나는지를 재는 것입니다. 개별 프레임의 오차는 집계 과정에서 상당 부분 상쇄되기 때문에, 프레임 정확도에 매달리는 것보다 이 집계 오차를 직접 재고 줄이는 쪽이 노력 대비 효과가 큼니다. 상용 DOOH 측정 업체들이 파는 상품도 정확히 이 집계 지표들입니다.

병목에 대해서 한 가지 강조하고 싶은 게 있습니다. 이런 시스템의 병목은 대개 연산량이 아니라 입력 품질입니다. 얼굴이 40px 미만으로만 잡히는 설치 위치에서는 어떤 모델을 갖다 놔도 성능이 안 나옵니다. 모델 교체를 고민하기 전에 카메라 높이·각도·화각을 조정해서 통행자 얼굴이 더 크고 정면에 가깝게 잡히도록 만드는 것이 훨씬 싸고 효과가 큰 개선인 경우가 많습니다. 비용 측면에서는 전 프레임 추론을 고집할 이유가 없습니다. 보행자 통행 속도를 감안하면 5~10fps 샘플링으로도 트랙당 충분한 프레임이 확보되고, 2번에서 말씀드린 품질 기반 선별과 결합하면 연산량을 크게 줄이면서 정확도는 오히려 지킬 수 있습니다. 정리하면, 우선순위는 집계 오차 측정 체계 구축 → 카메라 설치 최적화 → 프레임 선별 도입 → 모델 업그레이드 순서를 권합니다.

참고 자료

- [Quividi Audience Measurement Platform](#) — 상용 DOOH 측정의 상품 구성을 보여주는 레퍼런스. 광고주에게 판매되는 것은 OTS(광고를 볼 기회가 있었던 통행자 수), 주목 시간, 체류 시간, 인구통계 구성비 같은 집계 지표이며, 최적화 목표를 집계 오차로 설정하라는 본문 권고가 상용 서비스의 실제 운영 방식과 일치함을 보여줍니다.

- [Efficient video face recognition based on frame selection \(PeerJ CS, 2021\)](#) —
품질 기반 프레임 선별로 처리 프레임 수를 줄이면서도 정확도를 유지·개선할 수 있음을 실증한 연구.
정확도와 비용이 반드시 트레이드오프가 아니라는 본문 논거의 출처입니다.